

Predicción de vida útil remanente y priorización de mantenimiento en motores turbofan

Lautaro García Conejero
Universidad de San Andrés
Buenos Aires, Argentina
lgarciaconejero@udesa.edu.ar

Franco Needleman
Universidad de San Andrés
Buenos Aires, Argentina
fneedleman@udesa.edu.ar

Abstract—Este trabajo aborda la predicción de Remaining Useful Life (RUL) en motores turbofan a partir del conjunto NASA C-MAPSS. Se entrenan modelos supervisados separados para los subconjuntos FD001, FD002, FD003 y FD004, respetando sus diferencias en condiciones operativas y modos de falla. La representación principal se basa en características temporales calculadas sobre ventanas de sensores y settings, con modelos finales de LightGBM y XGBoost según el subset. Para evitar leakage, la selección se realiza con validación por motores completos y cortes artificiales, reservando el test oficial para el reporte final. En el test oficial, FD001 y FD003 alcanzaron RMSE cercanos a 14 ciclos, mientras que FD002 y FD004 obtuvieron RMSE cercanos a 25–26 ciclos debido a la mayor complejidad operativa. Además de la predicción de RUL, el proyecto incorpora una extensión operativa para priorización de mantenimiento y una lectura físico-operativa post-hoc que vincula sensores relevantes con variables físicas del motor y evalúa sensibilidad por perturbación.

Index Terms—Remaining Useful Life, C-MAPSS, mantenimiento predictivo, turbofan, LightGBM, XGBoost.

I. INTRODUCCIÓN

La estimación de vida útil remanente, o Remaining Useful Life (RUL), es una tarea central en mantenimiento predictivo porque permite anticipar fallas, planificar intervenciones y reducir tanto riesgos operativos como costos asociados a mantenimiento correctivo. En sistemas industriales complejos, como motores turbofan, el deterioro no suele observarse directamente: debe inferirse a partir de señales de sensores, condiciones de operación y patrones temporales de degradación. La entrada del sistema es la historia parcial de sensores y condiciones operativas de un motor hasta un ciclo observado, y la salida es una predicción numérica del RUL en ciclos restantes.

El conjunto NASA C-MAPSS es un benchmark ampliamente utilizado para estudiar pronóstico de fallas en motores aeronáuticos simulados [1], [2]. Sus datos combinan trayectorias *run-to-failure* de entrenamiento, donde se conoce el ciclo final de cada motor, con trayectorias de test truncadas, donde el objetivo es predecir el RUL en el último ciclo observado. Esta diferencia obliga a construir una evaluación cuidadosa: durante el entrenamiento puede derivarse el RUL a partir de la vida completa, mientras que en test solo se dispone de la historia parcial del motor.

El problema no es homogéneo entre subsets. FD001 y FD003 tienen una única condición operativa, mientras que

FD002 y FD004 incorporan múltiples regímenes de operación. Además, FD003 y FD004 incluyen más de un modo de falla. Por este motivo, el trabajo adopta modelos finales separados por subset en lugar de un único modelo global. La estrategia combina features temporales, control de condiciones operativas cuando corresponde, RUL cap para entrenamiento y modelos de boosting basados en LightGBM [3] y XGBoost [4].

La contribución operativa del proyecto va más allá de reportar métricas agregadas. Las predicciones finales se traducen en rankings de prioridad de mantenimiento y reglas simples de decisión, orientadas a distinguir motores que requieren intervención urgente de aquellos que pueden continuar bajo monitoreo. Como complemento, se agrega una interpretación físico-operativa que agrupa importancias por sensor base, vincula sensores con variables físicas del turbofan y evalúa la sensibilidad del modelo frente a perturbaciones de señales relevantes.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

El conjunto C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) contiene simulaciones de degradación de motores turbofan bajo distintos escenarios operativos y de falla [1], [2]. Cada fila representa el estado de una unidad en un ciclo de operación e incluye el identificador del motor, el ciclo, tres variables de configuración operativa (*settings*) y 21 sensores. Los datos de entrenamiento son trayectorias *run-to-failure*: para cada motor se observa la vida completa hasta la falla. En cambio, los datos de test están truncados y solo muestran la historia disponible hasta un ciclo final observado; el RUL real de ese último ciclo se entrega por separado para evaluación. En entrenamiento, el RUL se define como la diferencia entre el ciclo final del motor y el ciclo actual.

TABLE I
TAMAÑO, CONDICIONES OPERATIVAS Y MODOS DE FALLA DE LOS SUBCONJUNTOS C-MAPSS

Subset	Train	Test	Cond.	Modos de falla
FD001	100	100	1	1
FD002	260	259	6	1
FD003	100	100	1	2
FD004	249	248	6	2

La Tabla I resume las diferencias principales entre subconjuntos. El análisis exploratorio completo se documenta en los notebooks de EDA, donde se revisan distribuciones de ciclos y RUL, condiciones operativas, correlaciones sensor-RUL y patrones de degradación. FD002 y FD004 son más complejos que FD001 porque combinan múltiples condiciones operativas: cambios en los *settings* pueden modificar las lecturas de sensores aun cuando no haya degradación adicional. Por eso, las correlaciones globales sensor-RUL pueden quedar mezcladas con efectos de régimen. A su vez, FD003 y FD004 incorporan dos modos de falla, lo que introduce patrones de degradación latentes que no están etiquetados explícitamente por motor.

Para representar la evolución temporal se construyen ventanas retrospectivas por motor. En cada ciclo observado, las características se calculan usando solo la historia pasada disponible hasta ese punto, evitando leakage temporal. Para cada sensor o variable base se consideran estadísticos simples de ventana: último valor, media, desviación estándar, mínimo, máximo, delta respecto del inicio de la ventana y pendiente. Además, el objetivo de entrenamiento se limita con un RUL cap de 125 ciclos, de modo que el modelo priorice la zona cercana a falla y no sobreajuste diferencias poco informativas entre vidas remanentes largas.

Como el dataset no provee un conjunto de validación separado, la validación interna se construye separando motores completos del entrenamiento. No se aplicó aumento de datos clásico; los cortes artificiales se utilizaron para simular escenarios truncados de validación, análogos al test oficial.

En los subconjuntos con múltiples condiciones, FD002 y FD004, se agregan características de condición operativa y normalización por condición para separar cambios de régimen de señales de deterioro. En FD002, FD003 y FD004 también se usan características sensibles a degradación, como pendientes, deltas, volatilidad e interacciones entre sensores, con el objetivo de capturar dinámicas distintas de falla sin utilizar etiquetas supervisadas de modo de falla.

III. METODOLOGÍA

El pipeline final se formula como un problema de regresión supervisada de RUL. Sea $x_{i,t}$ el vector de sensores y *settings* del motor i en el ciclo t , y sea T_i el ciclo final de falla observado para ese motor en entrenamiento. El objetivo real se define como

$$RUL_{i,t} = T_i - t, \quad (1)$$

mientras que el objetivo usado para entrenar se limita superiormente mediante

$$RUL_{i,t}^{\text{cap}} = \min(RUL_{i,t}, 125). \quad (2)$$

Las métricas finales se calculan contra el RUL real sin cap. En test, el modelo predice el RUL del último ciclo observado de cada motor, que representa una trayectoria truncada.

La ejecución final sigue una secuencia fija: lectura de datos, cálculo de RUL, construcción de ventanas temporales, separación por motores, entrenamiento y selección, predicción

final del último ciclo de cada motor, evaluación y capa operativa. Para evitar leakage, la validación se realiza por motores completos y no por filas individuales; las unidades usadas para validación no aparecen en entrenamiento. Sobre esos motores se generan cortes artificiales que simulan trayectorias truncadas, y todas las ventanas usan solo ciclos pasados hasta el punto observado. El test oficial se reserva para la evaluación final una vez congelados modelos e hiperparámetros.

La representación temporal se construye con ventanas retrospectivas por motor y punto de corte. Para cada sensor y *setting* se calculan último valor, media, desviación estándar, mínimo, máximo, delta y pendiente. La ventana indica cuántos ciclos recientes se usan para calcular esos estadísticos; el cap es el límite superior aplicado al objetivo de entrenamiento. Temporal refiere a estadísticos en ventana. Condición incorpora el régimen operativo estimado a partir de los *settings*, variables indicadoras y normalización de sensores por condición. Degradación, o *fault-sensitive*, agrega pendientes, deltas, volatilidad, aceleraciones e interacciones entre sensores relevantes. Las variables de condición y la normalización por condición se emplean en FD002 y FD004, donde existen múltiples regímenes operativos; en FD003, al haber una única condición operativa, la representación se concentra en características sensibles a degradación.

El preprocesamiento tabular y la estandarización de variables se implementaron con herramientas de scikit-learn [5].

TABLE II
CONFIGURACIÓN FINAL UTILIZADA PARA GENERAR PREDICCIONES OFICIALES POR SUBCONJUNTO

Subset	Modelo	Ventana	Cap	Representación
FD001	LightGBM	50	125	Temporal
FD002	XGBoost	50	125	Condición + degradación
FD003	LightGBM	50	125	Degradación
FD004	XGBoost	70	125	Condición + degradación

La Tabla II resume únicamente las configuraciones finales utilizadas para generar las predicciones oficiales. FD001 y FD003 usan LightGBM con objetivo quantile $\alpha = 0.4$, que estima un cuantil de la distribución objetivo en lugar de solo la media condicional, sin pesos de muestra. FD002 y FD004 usan XGBoost con objetivo de error cuadrático y pesos de muestra para ponderar rangos de RUL relevantes durante el ajuste. No se emplea un único modelo global porque los subconjuntos no comparten la misma complejidad: FD001 y FD003 tienen una sola condición operativa, FD002 y FD004 incluyen múltiples condiciones, y FD003 y FD004 incorporan múltiples modos de falla.

LightGBM y XGBoost son modelos de *gradient boosting* basados en árboles de decisión. Construyen un ensamble secuencial en el que cada nuevo árbol busca corregir errores residuales de los árboles anteriores. Son adecuados para este problema porque trabajan bien con datos tabulares, relaciones no lineales e interacciones entre sensores, *settings* y RUL, sin requerir una especificación manual de todas las formas funcionales posibles.

La evaluación considera MAE, RMSE, R^2 y el score C-MAPSS, una métrica asimétrica relevante en *prognostics*. Además, se reporta el indicador de error peligroso, definido como una sobreestimación del RUL real por más de 20 ciclos. Como extensión operativa, las predicciones se traducen en bandas de decisión de mantenimiento: intervención urgente, mantenimiento preventivo programado, monitoreo cercano y operación con monitoreo normal. También se agrega una interpretación físico-operativa post-hoc basada en importancia agrupada por sensor base, sensibilidad por perturbación y agrupación por área del motor; esta interpretación no modifica la selección de modelos ni sus hiperparámetros.

IV. EXPERIMENTOS, RESULTADOS Y DISCUSIÓN

A. Protocolo experimental y métricas

El protocolo experimental se diseñó para evitar fugas de información temporal. No se usó validación cruzada clásica ni split aleatorio por filas, porque ciclos distintos de un mismo motor comparten trayectoria, régimen operativo y degradación acumulada. En su lugar, la validación interna separó motores completos: las unidades de validación no aparecen en entrenamiento. Sobre esos motores se generaron cortes artificiales para simular trayectorias truncadas, equivalentes al uso real del test. Cuando fue necesario comparar candidatos finales, se usaron evaluaciones multi-split de robustez por unidades completas.

El test oficial se reservó hasta después de congelar modelos e hiperparámetros, y por lo tanto no se usó para búsqueda ni calibración de candidatos. Las calibraciones se hicieron solo sobre validación interna por motores completos y cortes artificiales; el test oficial se usó únicamente para el reporte final. La selección priorizó el score C-MAPSS en validación, con RMSE y error peligroso como criterios secundarios. Esto evita elegir modelos que optimicen solo error promedio pero produzcan sobreestimaciones riesgosas de RUL.

Antes de reportar resultados se consideran MAE, RMSE, R^2 , score C-MAPSS y error peligroso. El MAE mide el error absoluto medio; RMSE penaliza con más fuerza errores grandes; R^2 resume ajuste global. Para predicciones $\hat{y}_j$ y RUL real y_j :

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}. \quad (3)$$

El score C-MAPSS penaliza asimétricamente los errores y resulta central en *prognostics*, donde no todas las equivocaciones tienen el mismo costo operativo. Definimos $d_j = \hat{y}_j - y_j$, de modo que $d_j > 0$ indica una sobreestimación del RUL. El score por motor se calcula como

$$s_j = \begin{cases} \exp(-d_j/13) - 1, & d_j < 0, \\ \exp(d_j/10) - 1, & d_j \geq 0. \end{cases} \quad (4)$$

El score total es $S = \sum_j s_j$ y en las tablas reportamos también su promedio por motor. Se define error peligroso como una sobreestimación del RUL real por más de 20 ciclos;

es decir, una predicción que podría postergar una intervención necesaria.

B. Selección final de modelos

La selección final no buscó un único modelo global, porque los subsets C-MAPSS no son homogéneos. FD001 y FD003 tienen una sola condición operativa y quedaron mejor representados por LightGBM con objetivo quantile, que ayuda a controlar predicciones demasiado optimistas. FD002 y FD004 combinan seis condiciones operativas, por lo que requieren variables de condición, normalización por condición y features sensibles a degradación; en esas representaciones, XGBoost dio el mejor compromiso final.

La comparación metodológica mostró que las redes MLP y variantes menos específicas no fueron seleccionadas por menor estabilidad o peor balance entre C-MAPSS y error peligroso. En FD003 se exploraron patrones latentes, pero los pseudo-clusters no se usaron como features finales: no mejoraron el cierre y son difíciles de defender sin etiquetas reales de modo de falla por motor. La mejora más defendible fue enriquecer la representación temporal con pendientes, deltas, volatilidad e interacciones calculables solo con historia pasada.

TABLE III
MODELOS FINALES E HIPERPARÁMETROS CLAVE

Subset	Modelo	Rep.	Obj.	Clave
FD001	LGBM	temp. w50 c125	q=0.4	lr .03; n 1300; leaves 15
FD002	XGB	cond.+deg. w50 c125	MSE	lr .04; depth 3; n 650
FD003	LGBM	deg. w50 c125	q=0.4	lr .03; n 1300; leaves 15
FD004	XGB	cond.+deg. w70 c125	MSE	lr .04; depth 3; n 650

En la columna “Clave”, “lr” refiere a la tasa de aprendizaje, “n” al número de estimadores, “leaves” al número de hojas en LightGBM y “depth” a la profundidad máxima en XGBoost.

La tabla resume las configuraciones finales usadas para generar predicciones oficiales. “cond.” indica variables y normalización por condición operativa, y “deg.” agrupa las características sensibles a degradación. Se reportan los hiperparámetros con mayor impacto en complejidad y ajuste: tasa de aprendizaje, número de estimadores, profundidad o número de hojas, objetivo y ventana temporal. Los restantes se mantuvieron según la configuración final reproducible, incluyendo regularización y muestreo de columnas o filas cuando correspondía.

C. Resultados oficiales

Las métricas oficiales se resumen en la Tabla IV.

TABLE IV
MÉTRICAS OFICIALES EN TEST FINAL

Subset	MAE	RMSE	R^2	C-M medio	Danger.
FD001	10.67	13.95	0.887	2.84	8.00%
FD002	16.62	25.28	0.779	20.66	5.02%
FD003	10.82	14.56	0.876	3.95	9.00%
FD004	17.91	26.07	0.771	18.55	6.45%

La tabla muestra dos grupos claros. FD001 y FD003 alcanzan menor RMSE y mayor R^2 , coherente con tener una sola condición operativa. FD003 es más complejo que FD001 por

sus dos modos de falla, pero la representación *fault-sensitive* mantiene errores globales cercanos al caso base. FD002 y FD004 tienen mayor error porque mezclan seis regímenes operativos: una misma señal de sensor puede cambiar por condición, no solo por degradación. FD004 es el escenario más exigente porque combina múltiples condiciones y dos modos de falla.

El C-MAPSS medio de FD002 y FD004 es bastante más alto que el de FD001/FD003, lo que indica que sus errores no solo son mayores en promedio, sino más costosos bajo la penalización asimétrica. Aun así, los errores peligrosos oficiales quedan relativamente contenidos: 5.02% en FD002 y 6.45% en FD004. Este contraste muestra el trade-off final: los modelos de condiciones múltiples aceptan más dispersión global, pero reducen parte del riesgo de sobreestimar severamente la vida remanente.

D. Errores por rango de RUL

La Tabla V y la Fig. 1 muestran dónde falla el algoritmo. En 0–30 ciclos todos los modelos tienen MAE bajo y 0% de errores peligrosos, que es la zona de mayor impacto operativo. En cambio, la banda 60–90 concentra la mayor proporción de sobreestimaciones peligrosas: el motor aún no parece inminente, pero una predicción optimista puede demorar mantenimiento. En 90+ aumenta el MAE, especialmente en FD002 y FD004, por la combinación de múltiples condiciones y el efecto del RUL cap.

Esta forma de error es coherente con entrenar usando $RUL^{cap} = 125$: el modelo aprende a priorizar cercanía a falla y comprime vidas remanentes largas. Operativamente esto es defendible porque distinguir con precisión entre valores altos de RUL es menos crítico que detectar motores cercanos a falla; sin embargo, sigue siendo una limitación real del sistema.

La Tabla V resume valores representativos por rango, y la Fig. 1 visualiza la concentración de errores peligrosos.

TABLE V
LECTURA RESUMIDA POR RANGOS DE RUL

Indicador	FD001	FD002	FD003	FD004
MAE 0–30	3.73	2.82	2.51	3.89
Danger. 0–30	0.00%	0.00%	0.00%	0.00%
Danger. 60–90	38.46%	17.39%	31.82%	24.39%
MAE 90+	12.94	28.58	12.85	28.18




Fig. 1. Porcentaje de errores peligrosos por rango de RUL y subset en el test oficial.

E. Priorización de mantenimiento

La capa operativa transforma la regresión de RUL en una regla de decisión: intervención urgente si $\hat{RUL} \leq 30$, mantenimiento preventivo si $30 < \hat{RUL} \leq 60$, monitoreo cercano si $60 < \hat{RUL} \leq 90$ y operación con monitoreo normal si $\hat{RUL} > 90$. En el test oficial, FD002 y FD004 acumulan más motores en todas las bandas por su mayor tamaño, mientras que FD001 y FD003 mantienen distribuciones más compactas. La Fig. 2 muestra cómo se convierte una salida numérica en una priorización práctica.




Fig. 2. Distribución de motores por bandas de decisión de mantenimiento según RUL predicho.

Esto no reemplaza una política real de mantenimiento, que debería incorporar costos, disponibilidad de repuestos e incertidumbre, pero sí provee una capa reproducible para ordenar motores según urgencia.

F. Interpretación físico-operativa

La interpretación físico-operativa se realizó como auditoría post-hoc: no participó en la selección de modelos ni de hiperparámetros. Agrupar por sensor base evita interpretar cientos de features temporales por separado; luego, agrupar por área del motor permite una lectura más cercana al sistema físico.

La sensibilidad por perturbación altera grupos de features asociadas a un sensor o área para medir cuánto cambia el desempeño.




Fig. 3. Áreas físico-operativas con mayor importancia media normalizada.

La Fig. 3 sugiere que HPC es el área más relevante, con sensores como Ps30, T30 y P30. La sensibilidad por perturbación también ubica a HPC como el área más sensible. Otras señales relevantes aparecen en fan/spool, core spool y turbine/LPT. Esta lectura es compatible con patrones físicos del turbofan, pero no prueba causalidad ni identifica directamente el modo de falla.

G. Sobreajuste, fallas y limitaciones

El principal riesgo de leakage se mitigó con separación por motores completos y cortes artificiales contruados solo sobre historia pasada. El riesgo de ajustar al test se redujo reservando el test oficial hasta el final. Aun así, hay limitaciones importantes: el RUL cap mejora el foco en falla cercana pero empeora RUL alto; FD002 y FD004 siguen siendo difíciles por mezclar condiciones operativas; y la ausencia de etiquetas de modo de falla por motor limita la interpretación física o latente.

Los modelos secuenciales podrían capturar dinámica temporal de forma más directa, pero en este trabajo la conversión a features tabulares temporales permitió usar LightGBM/XGBoost con mejor estabilidad, trazabilidad y control de leakage que las MLP probadas. La lectura final no es que el algoritmo resuelva todos los rangos por igual, sino que es más confiable cerca de falla, identifica una zona media de riesgo y transforma la predicción en señales útiles para priorización de mantenimiento.

V. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo abordó la predicción de vida útil remanente en motores turbofan C-MAPSS como un problema supervisado de regresión, cuidando especialmente la validación por motores completos para evitar leakage temporal. Los resultados muestran que no existe una única configuración óptima para todos los subconjuntos: LightGBM con representación

temporal y objetivo quantile fue más adecuado para FD001 y FD003, donde la condición operativa es única, mientras que XGBoost con características sensibles a condición y degradación resultó más conveniente para FD002 y FD004, que combinan múltiples regímenes operativos. Además de las métricas globales, el análisis por rangos de RUL mostró que los modelos son más confiables cerca de la falla, y la capa de decisión permitió traducir las predicciones en prioridades de mantenimiento.

Como trabajo futuro, sería relevante explorar modelos secuenciales que aprendan directamente de la serie temporal, incorporar estimaciones de incertidumbre para acompañar cada predicción de RUL y evaluar políticas de mantenimiento que consideren costos reales de intervención, disponibilidad de repuestos y riesgo operativo. También podría profundizarse la interpretación físico-operativa con técnicas de explicabilidad más robustas y con información adicional sobre modos de falla, ya que en este trabajo dicha lectura se utiliza como auditoría post-hoc y no como diagnóstico causal.

REFERENCES

- [1] NASA Prognostics Center of Excellence, "C-MAPSS Jet Engine Simulated Data," NASA Open Data Portal, 2025, accessed: 2026-07-08. [Online]. Available: <https://data.nasa.gov/dataset/cmapss-jet-engine-simulated-data>
- [2] A. Saxena, K. Goebel, D. Simon, and N. Eklund, "Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation," in *2008 International Conference on Prognostics and Health Management*. IEEE, 2008, pp. 1–9.
- [3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [4] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.
- [5] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.