

Predicción de vida útil remanente y priorización de mantenimiento en motores turbofan

Autor 1

Universidad / Departamento
Ciudad, País
email u ORCID

Autor 2

Universidad / Departamento
Ciudad, País
email u ORCID

Autor 3

Universidad / Departamento
Ciudad, País
email u ORCID

Abstract—Este trabajo aborda la predicción de Remaining Useful Life (RUL) en motores turbofan a partir del conjunto NASA C-MAPSS. Se entrenan modelos supervisados separados para los subconjuntos FD001, FD002, FD003 y FD004, respetando sus diferencias en condiciones operativas y modos de falla. La representación principal se basa en características temporales calculadas sobre ventanas de sensores y settings, con modelos finales de LightGBM y XGBoost según el subset. Para evitar leakage, la selección se realiza con validación por motores completos y cortes artificiales, reservando el test oficial para el reporte final. Los resultados finales se reportan mediante métricas de regresión, score C-MAPSS y análisis operativo de errores peligrosos por rango de RUL. Además de la predicción de RUL, el proyecto incorpora una extensión operativa para priorización de mantenimiento y una lectura físico-operativa post-hoc que vincula sensores relevantes con variables físicas del motor y evalúa sensibilidad por perturbación.

Index Terms—Remaining Useful Life, C-MAPSS, mantenimiento predictivo, turbofan, LightGBM, XGBoost.

I. INTRODUCCIÓN

La estimación de vida útil remanente, o Remaining Useful Life (RUL), es una tarea central en mantenimiento predictivo porque permite anticipar fallas, planificar intervenciones y reducir tanto riesgos operativos como costos asociados a mantenimiento correctivo. En sistemas industriales complejos, como motores turbofan, el deterioro no suele observarse directamente: debe inferirse a partir de señales de sensores, condiciones de operación y patrones temporales de degradación. La entrada del sistema es la historia parcial de sensores y condiciones operativas de un motor hasta un ciclo observado, y la salida es una predicción numérica del RUL en ciclos restantes.

El conjunto NASA C-MAPSS es un benchmark ampliamente utilizado para estudiar pronóstico de fallas en motores aeronáuticos simulados [1], [2]. Sus datos combinan trayectorias *run-to-failure* de entrenamiento, donde se conoce el ciclo final de cada motor, con trayectorias de test truncadas, donde el objetivo es predecir el RUL en el último ciclo observado. Esta diferencia obliga a construir una evaluación cuidadosa: durante el entrenamiento puede derivarse el RUL a partir de la vida completa, mientras que en test solo se dispone de la historia parcial del motor.

El problema no es homogéneo entre subsets. FD001 y FD003 tienen una única condición operativa, mientras que FD002 y FD004 incorporan múltiples regímenes de operación.

Además, FD003 y FD004 incluyen más de un modo de falla. Por este motivo, el trabajo adopta modelos finales separados por subset en lugar de un único modelo global. La estrategia combina features temporales, control de condiciones operativas cuando corresponde, RUL cap para entrenamiento y modelos de boosting basados en LightGBM [3] y XGBoost [4].

La contribución operativa del proyecto va más allá de reportar métricas agregadas. Las predicciones finales se traducen en rankings de prioridad de mantenimiento y reglas simples de decisión, orientadas a distinguir motores que requieren intervención urgente de aquellos que pueden continuar bajo monitoreo. Como complemento, se agrega una interpretación físico-operativa que agrupa importancias por sensor base, vincula sensores con variables físicas del turbofan y evalúa la sensibilidad del modelo frente a perturbaciones de señales relevantes.

II. CONJUNTO DE DATOS Y CARACTERÍSTICAS

El conjunto C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) contiene simulaciones de degradación de motores turbofan bajo distintos escenarios operativos y de falla [1], [2]. Cada fila representa el estado de una unidad en un ciclo de operación e incluye el identificador del motor, el ciclo, tres variables de configuración operativa (*settings*) y 21 sensores. Los datos de entrenamiento son trayectorias *run-to-failure*: para cada motor se observa la vida completa hasta la falla. En cambio, los datos de test están truncados y solo muestran la historia disponible hasta un ciclo final observado; el RUL real de ese último ciclo se entrega por separado para evaluación. En entrenamiento, el RUL se define como la diferencia entre el ciclo final del motor y el ciclo actual.

TABLE I
TAMAÑO, CONDICIONES OPERATIVAS Y MODOS DE FALLA DE LOS SUBCONJUNTOS C-MAPSS

Subset	Train	Test	Cond.	Modos de falla
FD001	100	100	1	1
FD002	260	259	6	1
FD003	100	100	1	2
FD004	249	248	6	2

La Tabla I resume las diferencias principales entre subconjuntos. FD002 y FD004 son más complejos que FD001 porque combinan múltiples condiciones operativas: cambios en los *settings* pueden modificar las lecturas de sensores aun cuando no haya degradación adicional. Por eso, las correlaciones globales sensor-RUL pueden quedar mezcladas con efectos de régimen. A su vez, FD003 y FD004 incorporan dos modos de falla, lo que introduce patrones de degradación latentes que no están etiquetados explícitamente por motor.

Para representar la evolución temporal se construyen ventanas retrospectivas por motor. En cada ciclo observado, las características se calculan usando solo la historia pasada disponible hasta ese punto, evitando leakage temporal. Para cada sensor o variable base se consideran estadísticos simples de ventana: último valor, media, desviación estándar, mínimo, máximo, delta respecto del inicio de la ventana y pendiente. Además, el objetivo de entrenamiento se limita con un RUL cap de 125 ciclos, de modo que el modelo priorice la zona cercana a falla y no sobreajuste diferencias poco informativas entre vidas remanentes largas.

Como el dataset no provee un conjunto de validación separado, la validación interna se construye separando motores completos del entrenamiento. No se aplicó aumento de datos clásico; los cortes artificiales se utilizaron para simular escenarios truncados de validación, análogos al test oficial.

En los subconjuntos con múltiples condiciones, FD002 y FD004, se agregan características de condición operativa y normalización por condición para separar cambios de régimen de señales de deterioro. En FD002, FD003 y FD004 también se usan características sensibles a degradación, como pendientes, deltas, volatilidad e interacciones entre sensores, con el objetivo de capturar dinámicas distintas de falla sin utilizar etiquetas supervisadas de modo de falla.

III. METODOLOGÍA

El pipeline final se formula como un problema de regresión supervisada de RUL. Sea $x_{i,t}$ el vector de sensores y *settings* del motor i en el ciclo t , y sea T_i el ciclo final de falla observado para ese motor en entrenamiento. El objetivo real se define como

$$RUL_{i,t} = T_i - t, \quad (1)$$

mientras que el objetivo usado para entrenar se limita superiamente mediante

$$RUL_{i,t}^{\text{cap}} = \min(RUL_{i,t}, 125). \quad (2)$$

Las métricas finales se calculan contra el RUL real sin cap. En test, el modelo predice el RUL del último ciclo observado de cada motor, que representa una trayectoria truncada.

La ejecución final sigue una secuencia fija: lectura de datos, cálculo de RUL, construcción de ventanas temporales, separación por motores, entrenamiento y selección, predicción final del último ciclo de cada motor, evaluación y capa operativa. Para evitar leakage, la validación se realiza por motores completos y no por filas individuales; las unidades usadas para validación no aparecen en entrenamiento. Sobre esos

motores se generan cortes artificiales que simulan trayectorias truncadas, y todas las ventanas usan solo ciclos pasados hasta el punto observado. El test oficial se reserva para la evaluación final una vez congelados modelos e hiperparámetros.

La representación temporal se construye con ventanas retrospectivas por motor y punto de corte. Para cada sensor y *setting* se calculan último valor, media, desviación estándar, mínimo, máximo, delta y pendiente. La ventana indica cuántos ciclos recientes se usan para calcular esos estadísticos; el cap es el límite superior aplicado al objetivo de entrenamiento. Temporal refiere a estadísticos en ventana. Condición incorpora el régimen operativo estimado a partir de los *settings*, variables indicadoras y normalización de sensores por condición. Degradación, o *fault-sensitive*, agrega pendientes, deltas, volatilidad, aceleraciones e interacciones entre sensores relevantes. Las variables de condición y la normalización por condición se emplean en FD002 y FD004, donde existen múltiples regímenes operativos; en FD003, al haber una única condición operativa, la representación se concentra en características sensibles a degradación.

TABLE II
CONFIGURACIÓN FINAL UTILIZADA PARA GENERAR PREDICCIONES OFICIALES POR SUBCONJUNTO

Subset	Modelo	Ventana	Cap	Representación
FD001	LightGBM	50	125	Temporal
FD002	XGBoost	50	125	Condición + degradación
FD003	LightGBM	50	125	Degradación
FD004	XGBoost	70	125	Condición + degradación

La Tabla II resume únicamente las configuraciones finales utilizadas para generar las predicciones oficiales. FD001 y FD003 usan LightGBM con objetivo quantile $\alpha = 0.4$, que estima un cuantil de la distribución objetivo en lugar de solo la media condicional, sin pesos de muestra. FD002 y FD004 usan XGBoost con objetivo de error cuadrático y pesos de muestra para ponderar rangos de RUL relevantes durante el ajuste. No se emplea un único modelo global porque los subconjuntos no comparten la misma complejidad: FD001 y FD003 tienen una sola condición operativa, FD002 y FD004 incluyen múltiples condiciones, y FD003 y FD004 incorporan múltiples modos de falla.

LightGBM y XGBoost son modelos de *gradient boosting* basados en árboles de decisión. Construyen un ensamble secuencial en el que cada nuevo árbol busca corregir errores residuales de los árboles anteriores. Son adecuados para este problema porque trabajan bien con datos tabulares, relaciones no lineales e interacciones entre sensores, *settings* y RUL, sin requerir una especificación manual de todas las formas funcionales posibles.

La evaluación considera MAE, RMSE, R^2 y el score C-MAPSS, una métrica asimétrica relevante en *prognostics*. Además, se reporta el indicador de error peligroso, definido como una sobreestimación del RUL real por más de 20 ciclos. Como extensión operativa, las predicciones se traducen en bandas de decisión de mantenimiento: intervención urgente, mantenimiento preventivo programado, monitoreo cercano y

TABLE III
MODELOS FINALES E HIPERPARÁMETROS CLAVE

Subset	Modelo	Rep.	W/Cap	Obj.	Clave
FD001	LGBM	temp.	50/125	quant. .4	lr .03; 1300; leaves 15
FD002	XGB	cond.+deg.	50/125	sq. err.	lr .04; depth 3; 650
FD003	LGBM	deg.	50/125	quant. .4	lr .03; 1300; leaves 15
FD004	XGB	cond.+deg.	70/125	sq. err.	lr .04; depth 3; 650

TABLE IV
MÉTRICAS OFICIALES EN TEST FINAL

Subset	MAE	RMSE	R^2	C-M medio	Danger.
FD001	10.67	13.95	0.887	2.84	8.00%
FD002	16.62	25.28	0.779	20.66	5.02%
FD003	10.82	14.56	0.876	3.95	9.00%
FD004	17.91	26.07	0.771	18.55	6.45%

operación con monitoreo normal. También se agrega una interpretación físico-operativa post-hoc basada en importancia agrupada por sensor base, sensibilidad por perturbación y agrupación por área del motor; esta interpretación no modifica la selección de modelos ni sus hiperparámetros.

IV. EXPERIMENTOS, RESULTADOS Y DISCUSIÓN

El protocolo experimental evitó el split aleatorio por filas. La selección se hizo con validación por motores completos, generando cortes artificiales para simular trayectorias truncadas similares al test. El test oficial se usó solo después de cerrar modelos e hiperparámetros. En validación se priorizó el score C-MAPSS, usando RMSE y error peligroso como criterios secundarios.

Antes de reportar resultados se consideran MAE, RMSE, R^2 , score C-MAPSS y error peligroso. Para predicciones $\hat{y}_j$ y RUL real y_j :

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}. \quad (3)$$

El score C-MAPSS penaliza asimétricamente los errores y es más relevante en *prognostics* que mirar solo RMSE. Se define error peligroso como una sobreestimación del RUL real por más de 20 ciclos.

La Tabla III resume solo las configuraciones finales usadas para generar predicciones oficiales. “cond.” indica variables y normalización por condición operativa, y “deg.” agrupa las características sensibles a degradación. No se reportan todos los hiperparámetros internos porque quedan trazados en los archivos de configuración.

La Tabla IV muestra que FD001 y FD003 alcanzan los errores más bajos, coherente con tener una sola condición operativa. FD002 y FD004 son más difíciles porque mezclan seis regímenes, y FD004 además combina esa variabilidad con dos modos de falla. Aun con mayor RMSE en FD002/FD004, la tasa de errores peligrosos queda contenida respecto de la dificultad de esos escenarios.

La Tabla V muestra que los modelos son más confiables cerca de la falla, justamente la zona de mayor impacto operativo. El rango 60–90 es el más delicado por sobreestimaciones

TABLE V
LECTURA RESUMIDA POR RANGOS DE RUL

Indicador	FD001	FD002	FD003	FD004
MAE 0–30	3.73	2.82	2.51	3.89
Danger. 0–30	0.00%	0.00%	0.00%	0.00%
Danger. 60–90	38.46%	17.39%	31.82%	24.39%
MAE 90+	12.94	28.58	12.85	28.18

TABLE VI
BANDAS DE DECISIÓN DE MANTENIMIENTO

Subset	Urgente	Prog. pronto	Monit. cercano	Continuar
FD001	22	16	13	49
FD002	61	37	47	114
FD003	21	17	16	46
FD004	55	30	39	124




Fig. 1. Importancia físico-operativa agregada por área del motor.

peligrosas. En RUL alto, especialmente en FD002 y FD004, el cap de 125 comprime predicciones y deteriora $RMSE/R^2$; esto es aceptable dentro del objetivo operativo, que prioriza detectar motores cercanos a falla.

La capa operativa transforma la regresión de RUL en una regla de decisión: intervención urgente si $R\hat{U}L \leq 30$, mantenimiento preventivo si $30 < R\hat{U}L \leq 60$, monitoreo cercano si $60 < R\hat{U}L \leq 90$ y operación con monitoreo normal si $R\hat{U}L > 90$. La Tabla VI permite pasar de métricas agregadas a una priorización accionable de motores.

La interpretación físico-operativa se realizó como auditoría post-hoc: no participó en la selección de modelos ni de hiperparámetros. Las importancias se agruparon por sensor base y luego por área física; además, la sensibilidad por perturbación altera grupos de features asociadas a un sensor o área para medir el cambio de desempeño. La Fig. 1 sugiere que HPC es el área más relevante, con sensores como Ps30, T30 y P30. La sensibilidad por perturbación también ubica a HPC como el área más sensible. Otras señales relevantes aparecen en fan/spool, core spool y turbine/LPT. Esta lectura es compatible con patrones físicos del turbofan, pero no prueba causalidad ni identifica directamente el modo de falla.

En términos de sobreajuste y fallas, el principal riesgo de leakage se mitigó con separación por motores completos y cortes artificiales construidos solo sobre historia pasada. El

riesgo de ajustar al test se redujo reservando el test oficial hasta el final. Las variantes globales o menos específicas no fueron adoptadas porque los subsets no son homogéneos; las MLP probadas fueron menos estables que los modelos de boosting tabular y los pseudo-clusters no mejoraron el cierre de FD003. La limitación central es que el RUL cap mejora la prioridad cerca de falla pero degrada la precisión en RUL alto. Además, al no existir etiquetas de modo de falla por motor, la lectura de patrones físicos o latentes debe entenderse como interpretativa y no supervisada.

V. CONCLUSIONES Y TRABAJO FUTURO

REFERENCES

- [1] NASA Prognostics Center of Excellence, “C-MAPSS Turbofan Engine Degradation Simulation Data Set,” NASA Ames Prognostics Data Repository, revisar URL y fecha de acceso antes de la entrega final.
- [2] A. Saxena, K. Goebel, D. Simon, and N. Eklund, “Damage propagation modeling for aircraft engine run-to-failure simulation,” in *2008 International Conference on Prognostics and Health Management*. IEEE, 2008, pp. 1–9.
- [3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “Lightgbm: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [4] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.